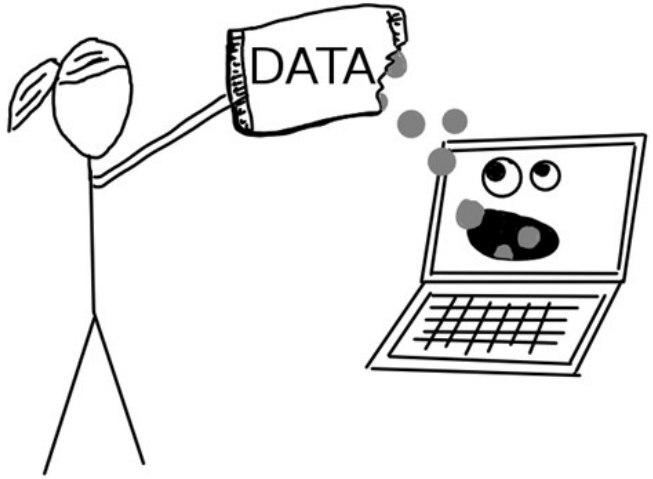

Machine Learning
Evaluation des modèles

2023

Abdelwahab Naji - Enseignant chercheur
Abdelwahab.naji@gmail.com
Laboratoire Signaux, Systèmes Distribués et Intelligence Artificielle (SSDIA)
ENSET de Mohammedia, Université Hassan II de Casablanca
https://www.youtube.com/c/AbdelwahabNaji

L'évaluation des modèles de machine learning

- **La tâche la plus importante dans un projet Machine Learning est: évaluer le modèle**
- **L'évaluation du modèle nous permet de mesurer à quel point il est bon avant de l'utiliser pour des données jamais vues**

Elle dépend de trois facteurs principaux:

- Le type de problème (classification, régression, etc.)
- Le contexte: Médecine, Banque, …
- Les données disponibles et les objectifs spécifiques

Les approches couramment utilisées pour évaluer les modèles de machine Learning :

1. **Séparation des données**
2. **Validation croisée (cross-validation)**
3. **Métriques de performance**
4. **Comparaison de modèles**
5. **Analyse des erreurs**

L'évaluation des modèles de machine learning

1) Séparation des données :

Divisez vos données en ensembles d'apprentissage (training set), de validation (validation set) et de test (test set).

- Utilisez un ensemble d'apprentissage pour entraîner le modèle
- Utilisez un ensemble de validation pour ajuster les hyperparamètres
- Utilisez un ensemble de test pour évaluer les performances finales du modèle

Cette approche permet d'estimer les performances sur des données non vues auparavant.

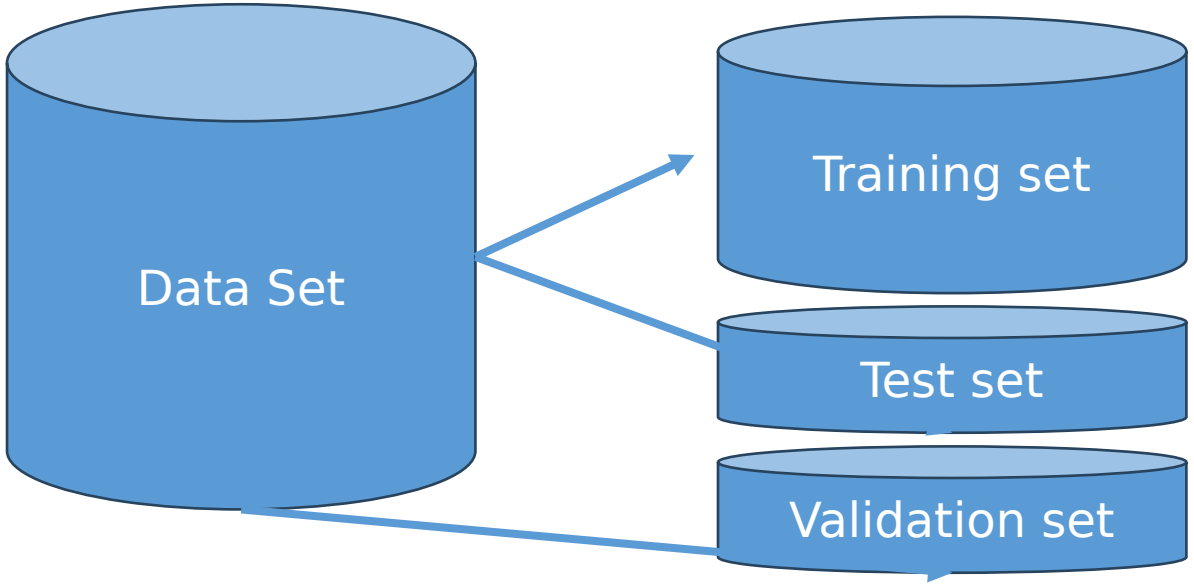

L'évaluation des modèles de machine learning

2) Validation croisée (cross-validation)

Si vous disposez d'un ensemble de données limité, la validation croisée est utile.

- Elle consiste à diviser les données en plusieurs plis (folds), à entraîner et à évaluer le modèle plusieurs fois en utilisant différentes combinaisons de plis pour l'entraînement et la validation.
- Cela permet d'obtenir une évaluation plus robuste du modèle.

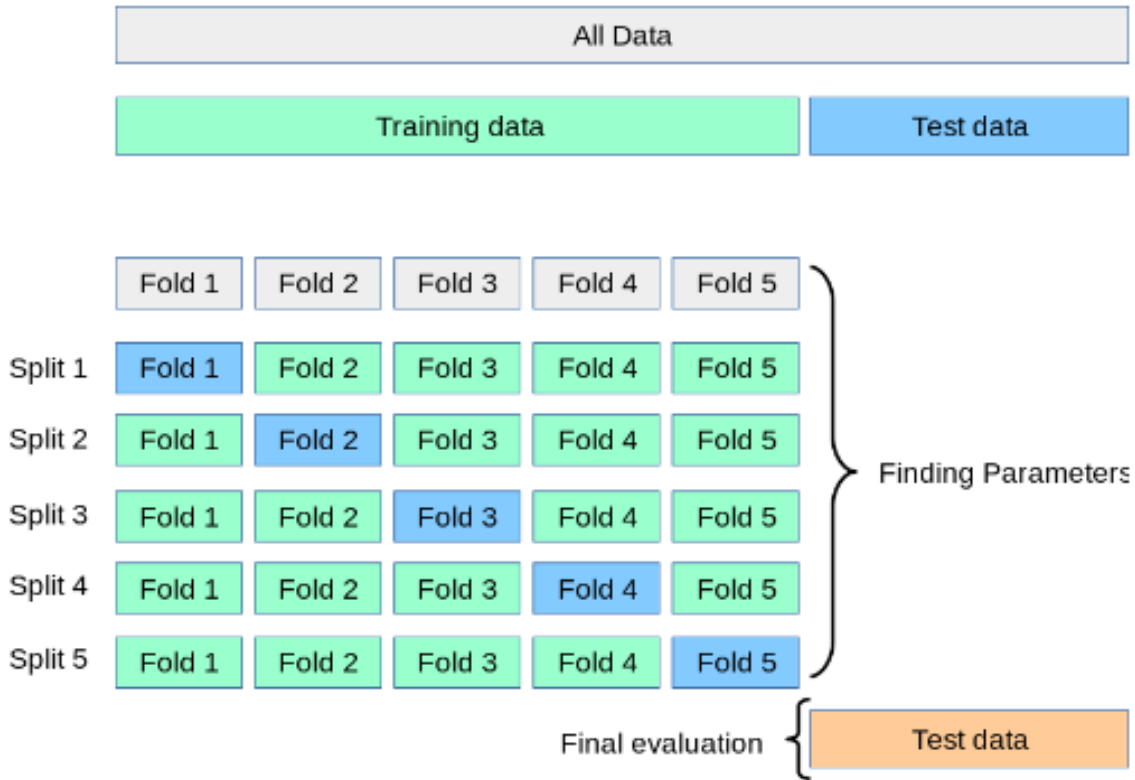

L'évaluation des modèles de machine learning

3) Métriques de performance

Dans la littérature, il existe plusieurs métriques

Sélectionnez les métriques de performance appropriées dépendent de:

- type de problème: Régression, classification, clustering
- Contexte: Finance, Banque, Santé, Société, Commerce…

Cette partie sera présentée en détail

L'évaluation des modèles de machine learning

4) Comparaison de modèles

Évaluez et comparez plusieurs modèles en utilisant les mêmes métriques de performance sur les mêmes ensembles de données.

Cela vous aidera à déterminer quel modèle fonctionne le mieux pour votre problème spécifique.

L'évaluation des modèles de Machine Learning

5) Analyse des erreurs

Examinez les erreurs du modèle pour comprendre les types d'erreurs qu'il commet et identifier les domaines où il peut être amélioré.

Cela peut vous aider à affiner votre modèle, à collecter des données supplémentaires ou à ajuster vos caractéristiques d'entrée.

Métriques d’évaluation

- pour évaluer le modèle, nous avons des métriques d’évaluation
- Ces métriques d’évaluation sont liées au type de modèle de machine learning
  - Modèle de classification
    - On utilise confusion matrix, accuracy, precision, recall pour évaluer un modèle de classification
  - Modèle de régression
    - On utilise MAE, RMSE, R^2… pour évaluer un modèle de régression
  - Clustering
    - On utilise le Coefficient de silhouette, Index de Davies-Bouldin (DBI)… pour évaluer des

Mesurer la performance d’un problème de classification

- $Matrice\ de\ confusion$
- $accuracy = \frac{TP+TN}{TP+TN+FP+FN}$
- $precision = \frac{TP}{TP+FP}$
- recall$= \frac{TP}{TP+FN}$
- **Pour bien mesurer la performance d’un modèle, quelle métrique est à utiliser ?**

Confusion matrix

- **Confusion matrix est une matrice m x m qui permet de mesurer la performance d'un modèle de classification.**
  - **Avec m est le nombre de classes de l'output**
  - **Pour une classification binaire, par exemple la classe peut être (spam ou non spam): la matrice est de 2x2**
  - **Pour u ion multiclass, par exemple la cla , chat, ou lapin) t de 3 x 3**

Actual		0	1
	0	TN	FP
	1	FN	TP
		Predicted	

Pour une classification binaire, confusion matrix contient quatre valeurs:

1.True negatives: réalité = 0 et la prédiction = 0

2.True positives: réalité = 1 et la prédiction = 1

Actual		A	B	C
	A	AA	AB	AC
	B	BA	BB	BC
	C	CA	CB	CC
		Predicted		

Pour une classification ayant trois classes,
confusion matrix contient neuf valeurs:

Confusion matrix

Selon le résultat de prédiction du modèle de classification, trouver les valeurs de la matrice

Actual_y
0
0
0
0
1
1
1
1
1
1

Predicted_y
0
1
0
0
1
0
1
0
1
1

Actual \ Predicted	0	1
0	TN	FP
1	FN	TP

```
import matplotlib.pyplot as plt
import numpy as np
from sklearn import metrics
from sklearn.metrics import ConfusionMatrixDisplay

actual_y = np.array([0,0,0,0,1,1,1,1,1,1])
predicted_y = np.array([0,1,0,0,1,0,1,0,1,1])

confusion_matrix = metrics.confusion_matrix(actual_y, predicted_y)
cm_display = metrics.ConfusionMatrixDisplay(confusion_matrix = confusion_matrix,
display_labels = [False, True])
cm_display.plot()
plt.show()
```

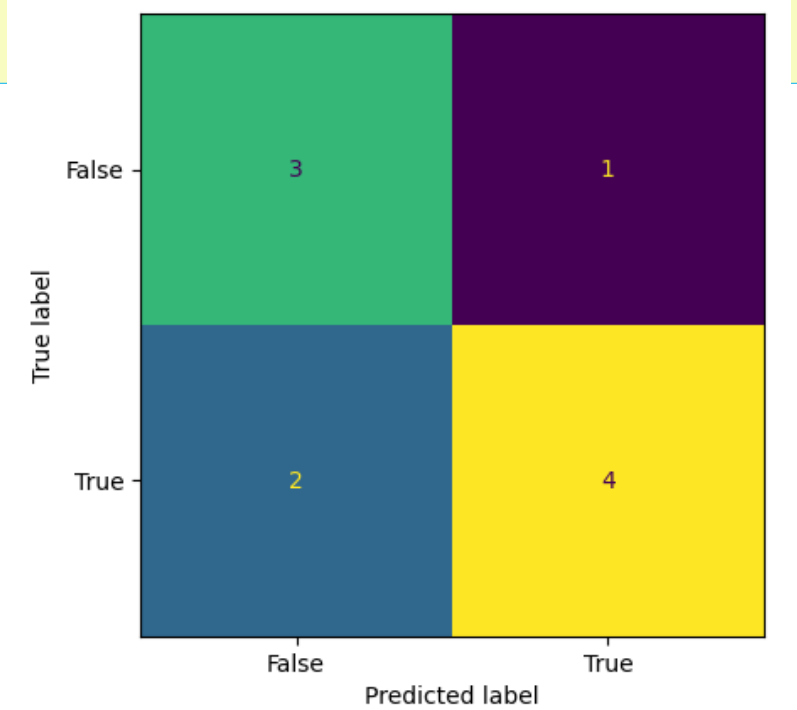

```
import numpy as np
from sklearn.model_selection import
train_test_split
import pandas as pnd

df=pnd.read_csv("diabetes.csv")

#convertir le dataframe en array
data=np.array(df)
#extraire la partie features
X=np.array([data[i,:len(cols)-1] for i in
range(len(data))])
#extraire la partie target
y=np.array([data[i,len(cols)-1] for i in
range(len(data))])

from sklearn.preprocessing import
StandardScaler
scaler= StandardScaler()
X = scaler.fit_transform(X)
X_train, X_test, y_train, y_test =
train_test_split(X, y, test_size=0.2,
random_state=44) #

from sklearn.linear_model import
```

```
import matplotlib.pyplot as plt
import numpy as np
from sklearn import metrics
from sklearn.metrics import
ConfusionMatrixDisplay

confusion_matrix =
metrics.confusion_matrix(y_test, y_predicted)
cm_display =
metrics.ConfusionMatrixDisplay(confusion_matrix =
confusion_matrix, display_labels = [False, True])
cm_display.plot()
plt.show()
```

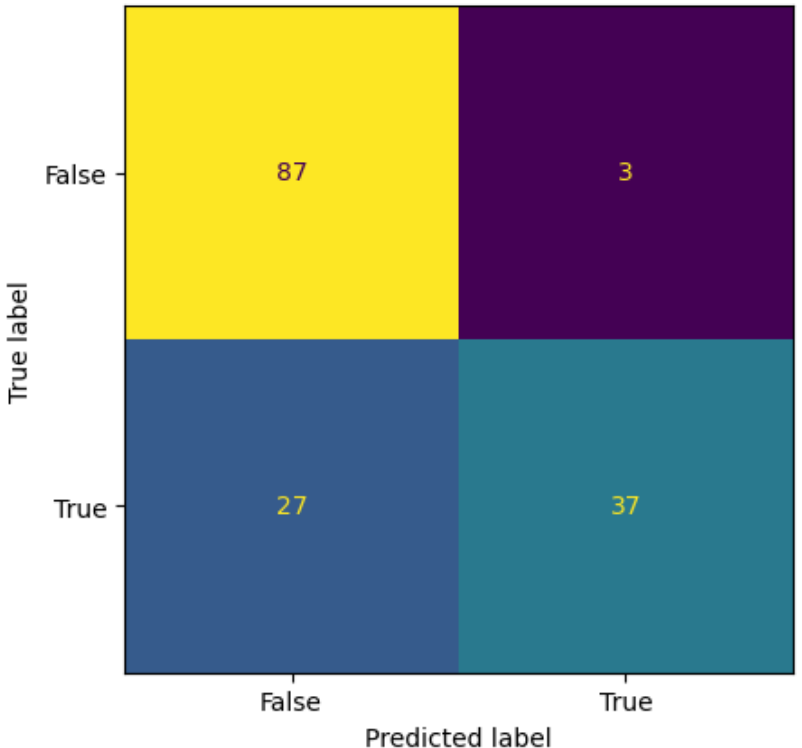

Mesurer la performance d'un problème de classification

- $accuracy = \frac{le\ nombre\ des\ éléments\ bien\ classés}{le\ nombre\ total\ des\ éléments} = \frac{TP+TN}{TP+TN+FP+FN}$

- Mesure à quel point notre modèle classe correctement les individus

- **Attention!! Pas très utile dans le cas de unbalanced datasets**

- **Exemple: détection des fraudes**
- **Si nous détectons des fraudes dans les données bancaires pour 1000 transactions**
  - **Réalité: 10 cas de fraude, 990 non fraude**
- **Si un modèle est mal formé de sorte qu'il prédit tous les 1000 (disons) points de données comme des non-fraudes.**
- **Si la précision est mesurée, cela montrera que ce modèle prédit correctement 990 points de données**
- **Dans de tels cas, si accuracy est utilisée, le modèle s'avérera être précis à 99 % en prédisant tous les cas de test comme non frauduleux.**
- **Le modèle précis à 99% sera complètement inutile.**

Mesurer la performance d'un problème de classification

- $accuracy = \frac{le\ nombre\ des\ éléments\ bien\ classés}{le\ nombre\ total\ des\ éléments} = \frac{TP+TN}{TP+TN+FP+FN}$

- Mesure à quel point notre modèle classe correctement les individus

Actual \ Predicted	0	1
0	990	0
1	10	0

- **Attention!! Pas très utile dans le cas de unbalanced datasets**

- **Exemple: détection de COVID19**
- **Si nous détectons des CAS COVID dans les données SANITAIRES pour 1000 PATIENTS**
  - **Réalité: 10 cas de COVID (P), 990 non ATTEINT DE COVID (N)**
- **Si un modèle est mal entrainé de sorte qu'il prédit tous les 1000 (disons) patients comme des non-atteints de covid.**
- **Si la précision est mesurée, cela montrera que ce modèle prédit correctement 990 points de données**
- **Dans de tels cas, si accuracy est utilisée, le modèle s'avérera être précis à 99 % en prédisant tous les cas de test comme non atteint de covid.**

$$accuracy = \frac{0 + 990}{1000}$$

- **Le modèle précis à 99% sera complètement inutile.**

Mesurer la performance d’un problème de classification

- $precision = \frac{TP}{TP+FP}$
- Ce rapport présente la capacité du modèle de classifier correctement la classe positive

- **Exemple: maintenance prédictive**
- **Dans le problème de la maintenance prédictive (capacité de prévoir à l'avance quand une machine doit être réparée), la métrique precision entre en jeu.**
  - **Le coût de la maintenance est généralement élevé**
  - **et, par conséquent, des prévisions incorrectes peuvent entraîner une perte pour l'entreprise**
- **Dans de tels cas, la capacité du modèle à classer correctement la classe positive et à diminuer le nombre de faux positifs est primordiale !**

- $precision = \frac{1}{1}$

Actual \ Predicted	0	1
0	990	0
1	10	1

Mesurer la performance d'un problème de classification

- Recall (sensitivity)$= \frac{TP}{TP+FN}$
- mesure la proportion d'instances positives réelles qui sont correctement identifiées par le modèle comme positives

- **Exemple: Problème de transaction frauduleuse**
- **La valeur de rappel sera très utile dans ce cas car une valeur de recall élevée indiquera qu'un grand nombre de cas de fraude ont été identifiés sur le nombre total**

- Recall (sensitivity)$= \frac{1}{1+10}$
- Recall (sensitivity)$= \frac{10}{10}$

Actual \ Predicted	0	1
0	990	0
1	0	10

Actual \ Predicted	0	1
0	990	0
1	10	1

- $accuracy = \frac{le\ nombre\ des\ éléments\ bien\ classés}{le\ nombre\ total\ des\ éléments} = \frac{500+500}{500+500+0+0}$

Actual	0	1
0	500	0
1	0	500

- $accuracy = \frac{970}{1000}$=97%

Actual	0	1
0	480	20
1	10	490

Mesurer la performance d’un problème de classification

- $\mathrm{f1Score} = 2 * \frac{precision * recall}{precision + recall}$

- **Exemple: identification de pièces d'avion qui pourraient nécessiter une réparation**
- **Le score F1 est la moyenne harmonique du rappel et de la précision et, par conséquent, équilibre les points forts de chacun.**
- **Il est utile dans les cas où le rappel et la précision peuvent être précieux.**
- **La précision sera nécessaire pour économiser sur les coûts de l'entreprise (car les pièces d'avion sont extrêmement chères)**
- **Et le rappel sera nécessaire pour s'assurer que la machinerie est stable et ne menace pas les vies humaines.**

Métrique	Formule	Description
Accuracy	(TP + TN) / (TP + TN + FP + FN)	Mesure la proportion d'échantillons correctement classés (positifs et négatifs) par rapport à l'ensemble total d'échantillons.
Précision	TP / (TP + FP)	Mesure la proportion d'échantillons positifs correctement classés par rapport à l'ensemble des échantillons prédits positifs. Elle met l'accent sur l'exactitude des prédictions positives.
F1-score	2 * (précision * rappel) / (précision + rappel)	F1-score est une mesure qui combine précision et rappel en une seule valeur. Il représente la moyenne harmonique de précision et de rappel. Il est utile lorsque vous voulez équilibrer précision et rappel pour évaluer les performances globales.
Rappel (Recall)	TP / (TP + FN)	Mesure la proportion d'échantillons positifs correctement classés par rapport à l'ensemble total des échantillons positifs. Il met l'accent sur la sensibilité du modèle à détecter les vrais positifs.

Mesurer la performance d’un problème de classification

- Le score ROC (Receiver Operating Characteristic) est une mesure utilisée pour évaluer les performances d'un modèle de classification binaire.
- Il est largement utilisé dans divers domaines tels que la médecine, la finance et la recherche
- Une courbe ROC montre le taux de vrais positifs (TPR), par rapport au taux de faux positifs (FPR) Pour différents seuils de scores de classification.

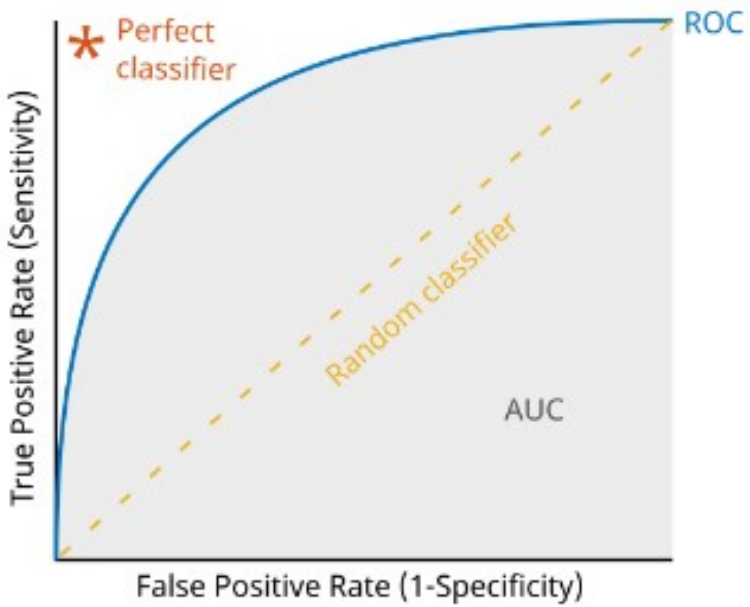

- L'aire sous une courbe ROC (AUC) correspond à l'intégrale de la courbe (valeurs TPR) par rapport aux valeurs FPR de zéro à un.
- Des valeurs AUC plus élevées indiquent de meilleures performances de classifieur.
- Un classificateur parfait attribue toujours correctement les observations de classe positives à la classe positive et a un TPR de 1 pour toutes les valeurs de seuil.
- Un classificateur aléatoire renvoie des valeurs de score aléatoires et a les mêmes valeurs pour le FPR et le TPR pour toutes les valeurs de seuil.

Mesurer la performance d'un problème de classification

- **Auc –ROC curve**

Principalement basée sur deux mesures:

- **True Postive Rate**

$$\text{TPR=recall}=\frac{TP}{TP+FN}$$

- **False Postive Rate**

$$\text{FPR}=\frac{FP}{TN+FN}$$

Métrique	Formule	Description
TPR (recall)	TP / (TP + FN)	Proportion d'échantillons positifs correctement classés par rapport à l'ensemble des positifs
FPR	FP / (FP + TN)	Proportion d'échantillons négatifs incorrectement classés par rapport à l'ensemble des négatifs
Précision	TP / (TP + FP)	Proportion d'échantillons positifs correctement classés par rapport à l'ensemble des prédictions
Spécificité	TN / (TN + FP)	Proportion d'échantillons négatifs correctement classés par rapport à l'ensemble des négatifs

Model selection in machine learning (choosing model validation strategy)

Resampling methods (méthodes de rééchantionnage)

- Se sont des techniques simples de réorganisation des échantillons de données pour vérifier si le modèle fonctionne bien sur des échantillons de données sur lesquels il n'a pas été formé.
- Le rééchantillonnage nous aide à comprendre si le modèle se généralisera bien.
- **Random Split**
- **Time-Based Split**
- **K-Fold Cross-Validation**

Model selection in machine learning (choosing model validation strategy)

Resampling methods (méthodes de rééchantionnage)

- Se sont des techniques simples de réorganisation des échantillons de données pour vérifier si le modèle fonctionne bien sur des échantillons de données sur lesquels il n'a pas été formé.
- Le rééchantillonnage nous aide à comprendre si le modèle se généralisera bien.
- **Random Split**
- **Time-Based Split**
- **K-Fold Cross-Validation**

Évaluer la performance de ML

- **Matrice de confusion (TP,TN,FP,FN)**
- **Precision**
- **Rappel (ou sensibilité)**
- **Précision ou rappel?**
- **Coefficient f1_score**

		Réalité	
		Positive	Négative
Prédiction	Positive	5 (TP)	1 (FP)
	négative	2 (FN)	2 (TN)

$$\text{precision} = \frac{TP}{TP+FP} \qquad \text{precision} = \frac{5}{5+1} = 83.3\%$$

$$\text{rappel} = \frac{TP}{TP+FN} \qquad \text{rappel} = \frac{5}{5+2} = 71.4\%$$

$$\text{Exactitude} \quad \frac{TP+TN}{TP+TN+FP+FN}$$

Évaluation de la Performance

https://docs.microsoft.com/fr-fr/azure/machine-learning/studio/evaluate-model-performance
https://docs.aws.amazon.com/fr_fr/machine-learning/latest/dg/cross-validation.html